파이썬 확률 통계

시각화를 통한 자료의 요약

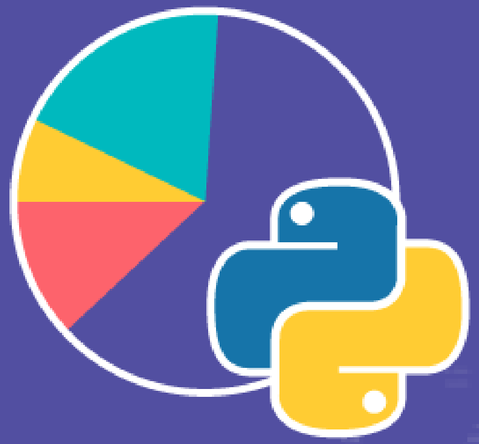

/* elice */

커리큘럼

1 **시각화를 통한 자료의 요약**

자료의 형태

범주형 자료의 요약

수치형 자료의 요약

분포의 모양

2 **논리적인 자료의 요약**

중심위치의 측도

퍼진 정도의 측도

상자그림

두 변수 자료의 요약

커리큘럼

3 **확률**

사건과 확률의 개념
순열과 조합
독립과 조건부 확률
확률분포

4 **가설검정 및 추론**

여러 가지 확률분포
통계적 추론
통계적 가설검정
검정의 종류와 과정

수강 대상

머신러닝, 빅데이터 공부를 위해
통계학 기초가 필요하신 분

파이썬으로 통계학을 해보고 싶은 분

논문 작성 등을 위해 통계분석이 필요하신 분

수강 목표

기초 통계학과 **파이썬**을 함께 배우며
원리부터 응용까지 시너지를 최대화합니다.

파이썬 기초 지식만으로도
자유자재로 **통계 분석**을 할 수 있습니다.

통계가 가진 힘을 알고,
통계에 대한 두려움을 떨칠 수 있습니다.

목차

자료의 형태

자료의 형태

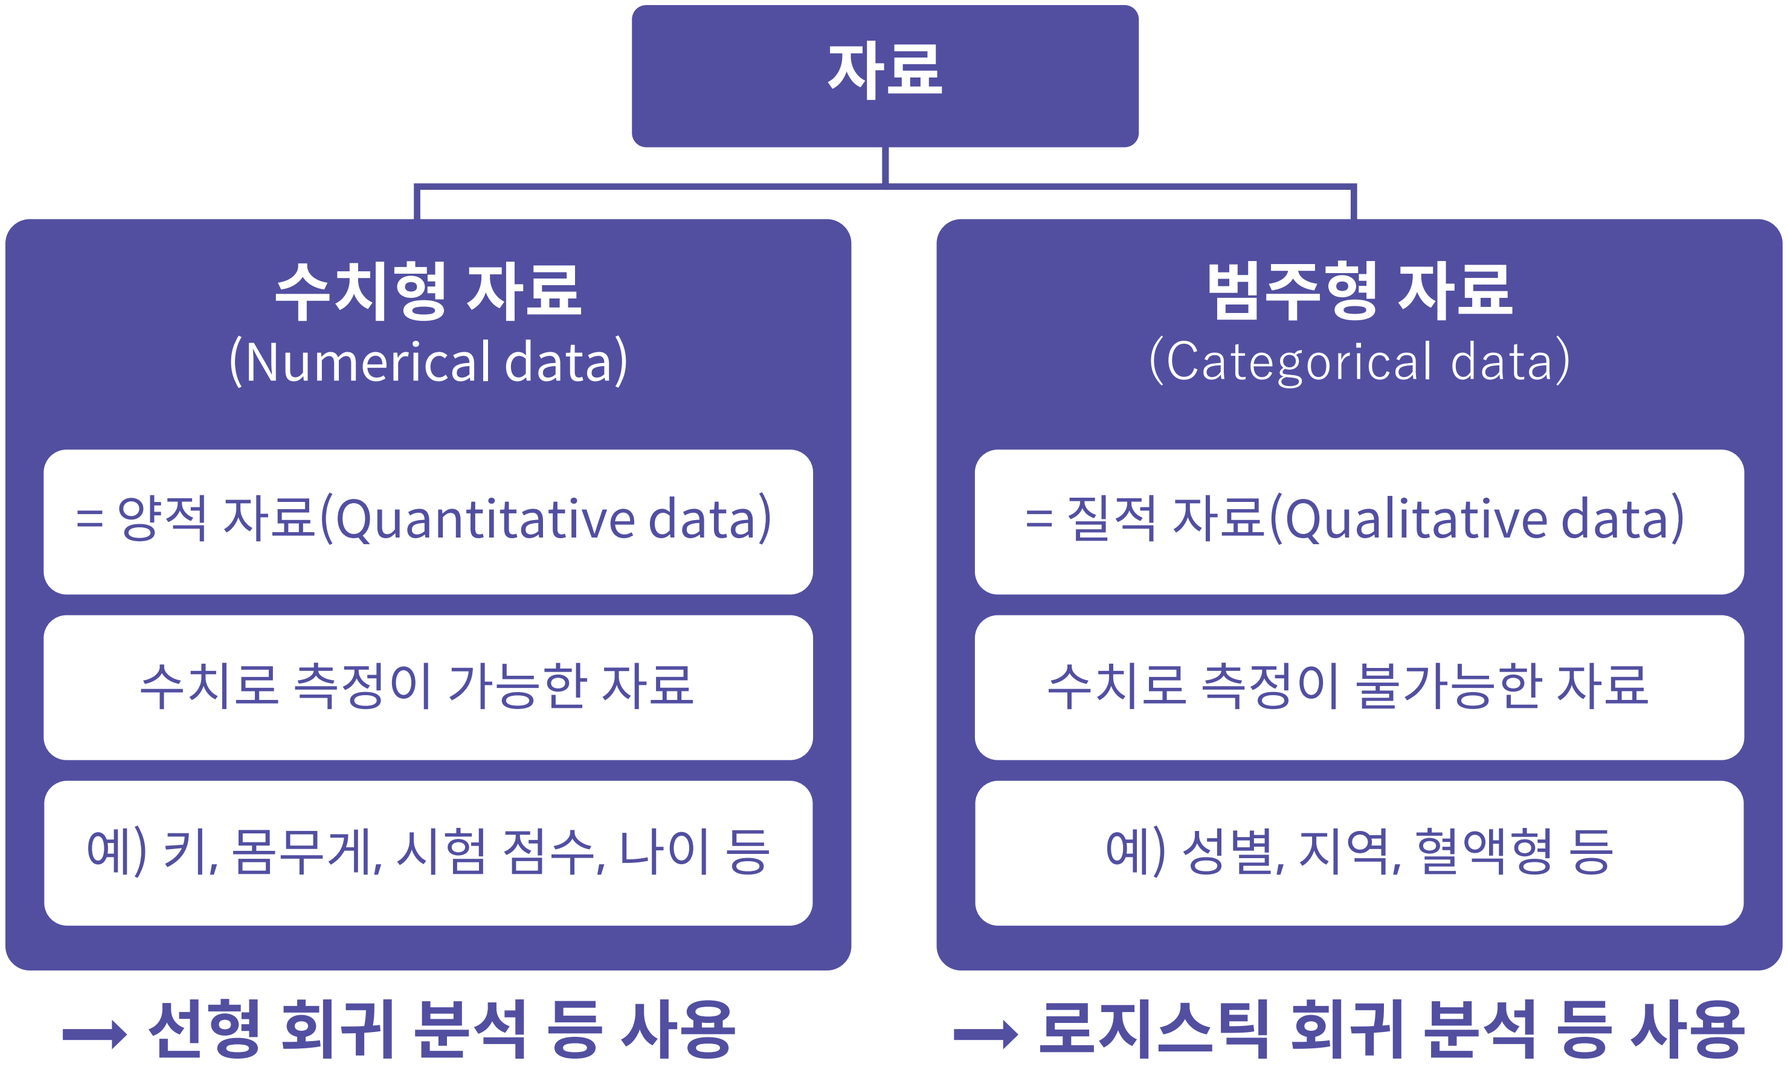

→ 선형 회귀 분석 등 사용

→ 로지스틱 회귀 분석 등 사용

수치형 자료

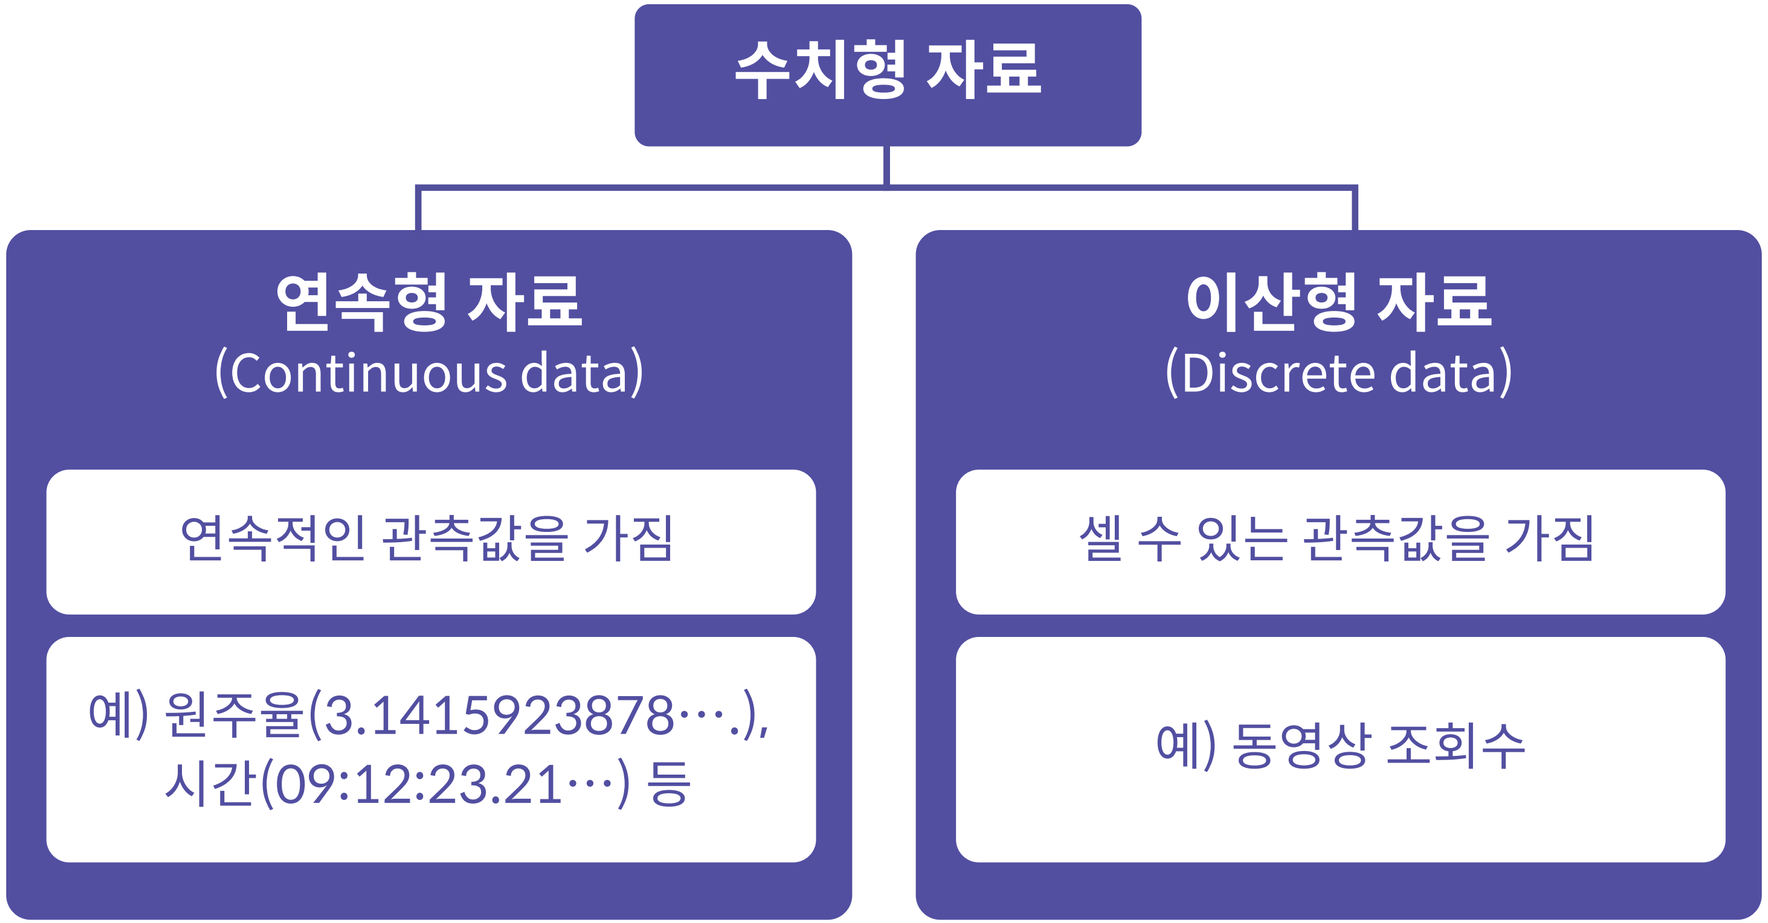
수치형 자료
연속형 자료
(Continuous data)
연속적인 관측값을 가짐
예) 원주율(3.1415923878….),
시간(09:12:23.21…) 등
이산형 자료
(Discrete data)
셀 수 있는 관측값을 가짐
예) 동영상 조회수

자료의 형태 구분 시, 주의점

범주형 자료와
수치 자료의 **구분**

≠

자료의 **숫자 표현 가능 여부**

범주형 자료가 숫자로 표현되는 경우

남녀 성별 구분 시, 남자를 1, 여자를 0으로 표현하는 경우, 숫자로 표현 되었으나 **범주형 자료**

수치형 자료를 범주형 자료로 변환하는 경우

나이 구분 시, 나이 값은 **수치형 자료**지만 10 ~ 19세, 20 ~29세 등 나이 대에 따라 **구간화 하면 범주형 자료**

수치형 자료 구분

연속형 자료 ≠ 이산형 자료

연속형 자료는 연속적인 관측

예) 시간 측정

어떤 순간은 09:12:23.21… 처럼 연속되고 있는 상태를 관측한 연속형 자료이나

평소에는 09시 12분으로 반올림하여 표현하여 이산형 자료로 사용

범주형 자료

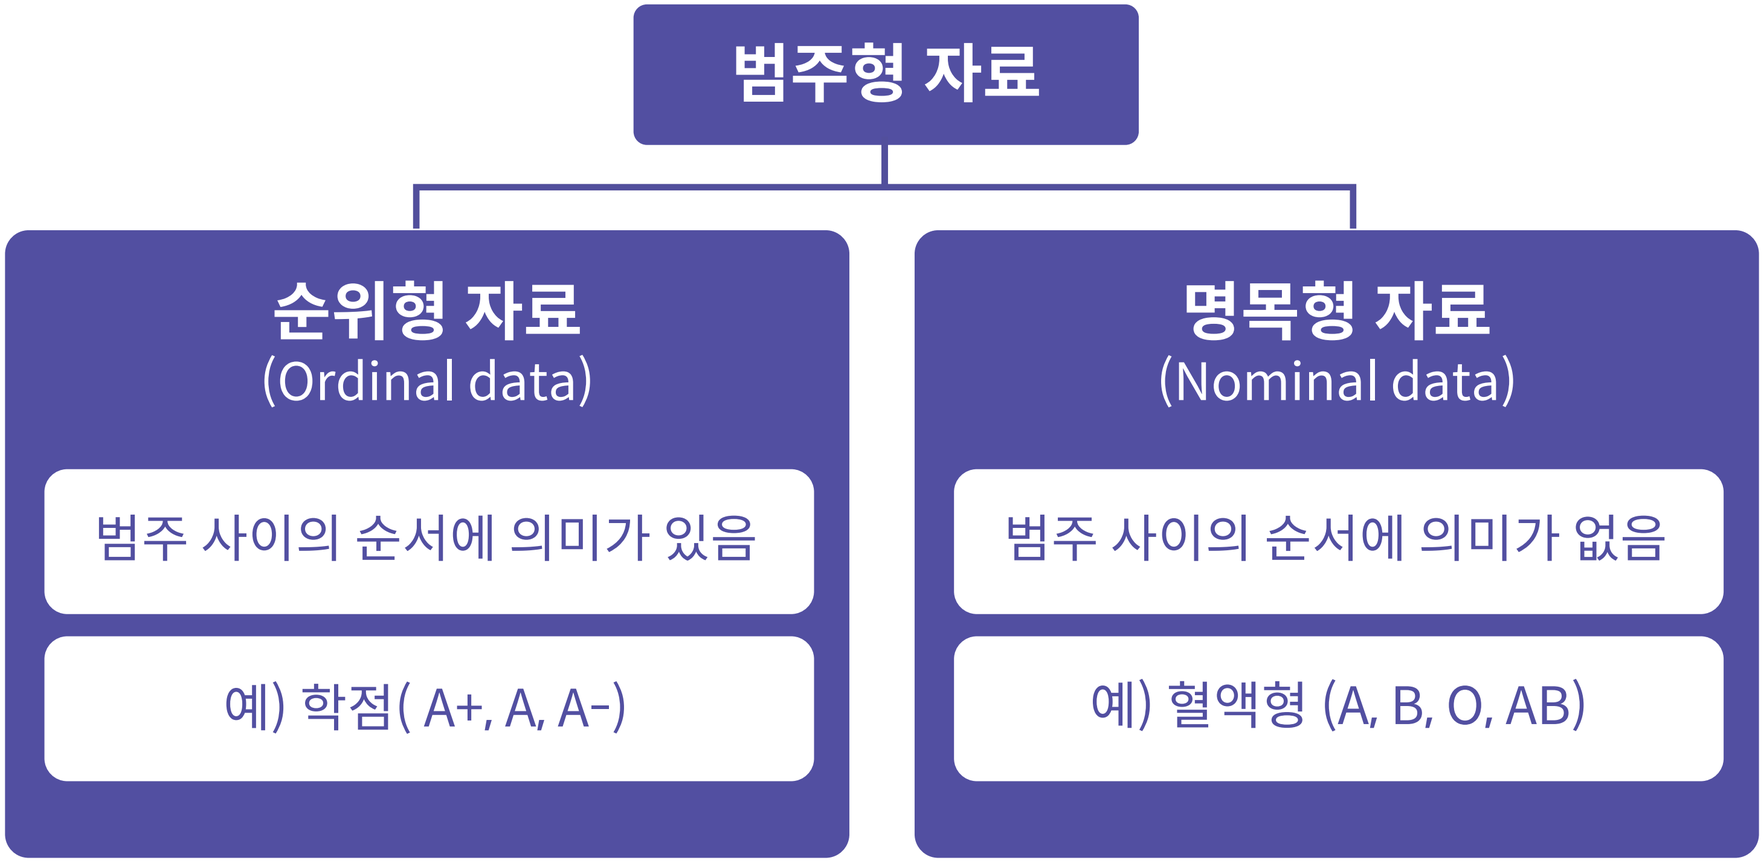
범주형 자료
순위형 자료
(Ordinal data)
범주 사이의 순서에 의미가 있음
예) 학점(A+, A, A-)
명목형 자료
(Nominal data)
범주 사이의 순서에 의미가 없음
예) 혈액형 (A, B, O, AB)

[퀴즈]
자료의 형태

범주형 자료의 요약

범주형 자료 요약

다수의 범주가
반복해서 관측

관측값의 크기보다
포함되는 범주에 관심

**범주형 자료
요약 필요**

각 범주에 속하는
관측값의 개수를 측정

전체에서 차지하는
각 범주의 비율 파악

효율적으로 범주 간의
차이점을 비교 가능

도수분포표

도수
(Frequency)

각 범주에 속하는 관측값의 **개수**

```
value_counts()
```

상대도수
(Relative Frequency)

도수를 자료의 **전체 개수**로 나눈 **비율**

```
value_counts(normalize=True)
```

도수분포표
(Frequency Table)

범주형 자료에서 **범주와 그 범주에 대응**하는 도수, 상대도수를 나열해 표로 만든 것

도수분포표 예시

강의 만족도 설문 (100명 조사)

범주	도수	상대도수
매우 만족	30	0.3
만족	10	0.1
보통	30	0.3
불만족	15	0.15
매우 불만족	15	0.15

도수

```
df[범주].value_counts()
```

value_counts() 함수를 이용해 **도수**를 구할 수 있습니다.

상대도수

```
df[범주].value_counts(normalize=True)
```

value_counts() 함수에 normalize=True 옵션을 주면
상대도수를 구할 수 있습니다.

도수분포표

몇 개의 범주를 기준으로 둘 것인지에 따라

다양한 도수분포표를 만들 수 있습니다.

한 가지 범주의 도수분포표

```
pd.crosstab(index = 범주, columns = “count”)
```

index로 설정한 범주에 해당하는 도수를 계산하여
도수분포표를 제작

두 가지 범주의 도수분포표

```
pd.crosstab(index = 범주, columns = 또 다른 범주)
```

index로 설정한 범주와 colums로 설정한 범주를 모두 만족하는 도수를 계산하여 **도수분포표**를 제작

범주형 자료의 요약: 그래프

원형그래프(Pie Chart)

```
plt.pie(수치, labels = 라벨)
```

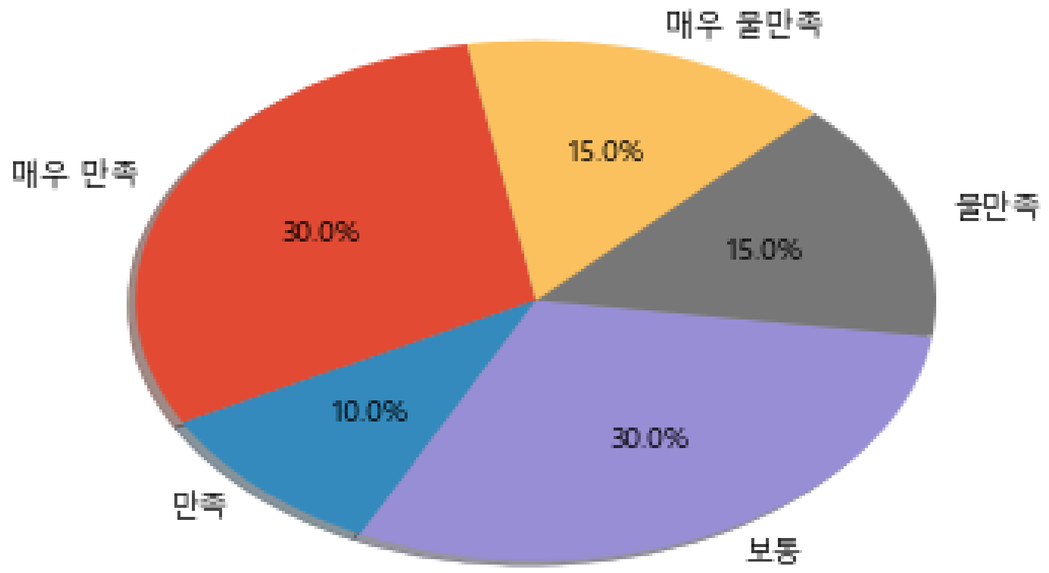

원형그래프(Pie Chart)

숫자의 나열보다 전체적인 분포를 이해하기 쉬운 그래프

원을 각 범주가 차지하는 비율로 중심각을 나눠 피자처럼 조각을 나눈 형태의 그림

장점

전체에서 범주가 차지하는 비율을 파악하기 쉬움

단점

범주 간 도수 비교 및 도수 크기 차이 파악이 어려움

막대그래프 (Bar Chart)

```
plt.bar(x = 라벨, height = 수치)
```

Y축 =
도수의 크기

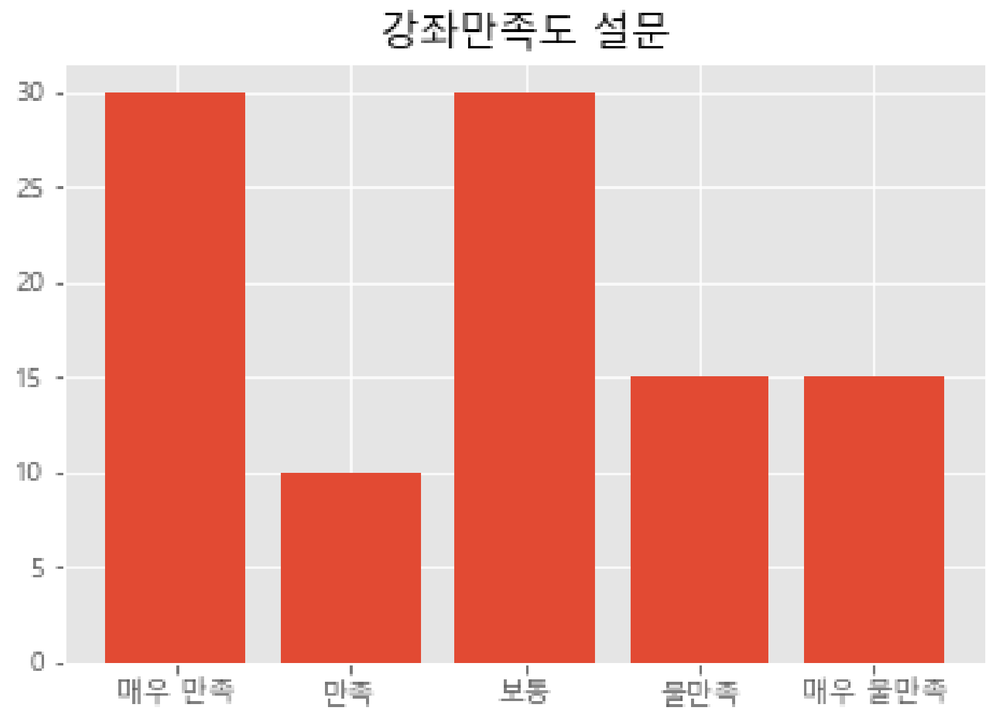

X축 = 범주

막대그래프 (Bar Chart)

각 범주에서 도수의 크기를 막대로 그림

그래프의 Y축 : 도수에 대한 눈금

그래프의 X축 : 범주를 나열

장점
각 범주가 가지는 도수의 크기 차이를 비교하기 쉬움

단점
각 범주가 차지하는 비율의 비교는 어려움

[실습]

범주형 자료 요약 : 도수와 상대도수, 도수분포표

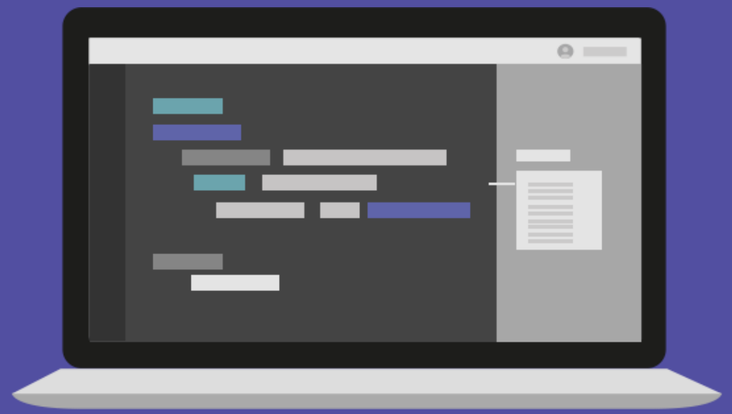

[실습]

범주형 자료 요약 : 원형 그래프, 막대 그래프

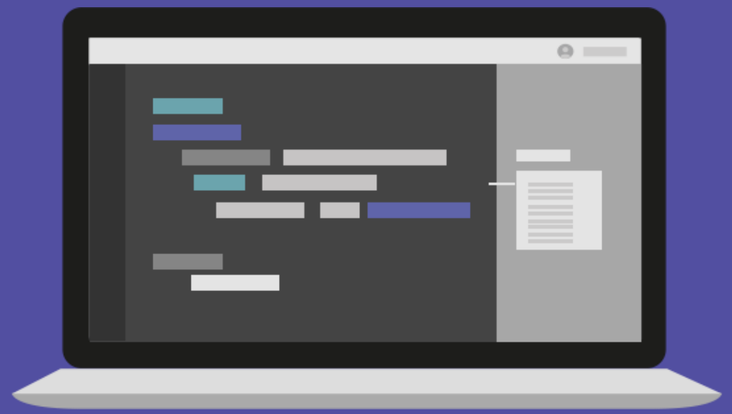

수치형 자료의 요약

이산형 자료 요약

관측된 수치 자료가 셀 수 있는 경우 ▶ 이산형 자료 요약

관측값의 종류 수

범주형 자료 요약 기법

연속형 자료 요약 기법

연속형 자료 요약

수치 자료가 연속적으로 관측 ▶ 연속형 자료 요약

관측값의 종류 수

많음 ↑ — 연속형 자료 요약 기법

적음 ↓ — 점도표, 도수분포표, 히스토그램, 상대도수다각형, 줄기-잎 그림

점도표 (dot diagram)

관측값의 개수가 상대적으로 적은 경우(20 또는 25이하) 사용

- 자료 전체의 개요를 파악 가능
- 모든 자료를 나타낼 수 있도록 줄 위에 각 관측값에 해당되는 점을 찍어 표시

연속형 자료의 경우 **중복된 정보**를 판단하기 어려움 ▶ 자료를 크기에 따라 묶어서 분석하는 것이 **효율적**

도수분포표(Frequency Table)

- 각 관측값에 대한 도수를 측정하여 도수분포표 작성
- 연속형 자료의 경우 다수의 구간(계급)으로 나누고
  각 구간마다 관측값의 개수(도수)로 작성

계급(Class)	계급구간	계급구간의 폭
위에서 나눈 구간	각 계급에 포함되는 값의 범위	계급구간의 크기

도수분포표 작성 순서

1. 자료의 범위 — 자료에서 최댓값과 최솟값을 찾아 자료의 범위를 구함
2. 계급의 폭 — 계급의 개수를 분포의 경향이 잘 드러날 수 있도록 정함
3. 계급구간 — 모든 관측 값을 포함하도록 계급구간의 경계점을 구함
4. 도수 — 각 계급구간에 속하는 관측값의 개수를 세어 계급의 도수를 더함
5. 상대도수 — 각 계급의 도수를 전체 관측값의 개수로 나눠 계급의 상대도수를 구함

수치형 자료의 요약: 그래프

히스토그램(Histogram)

Y 축 : 빈도

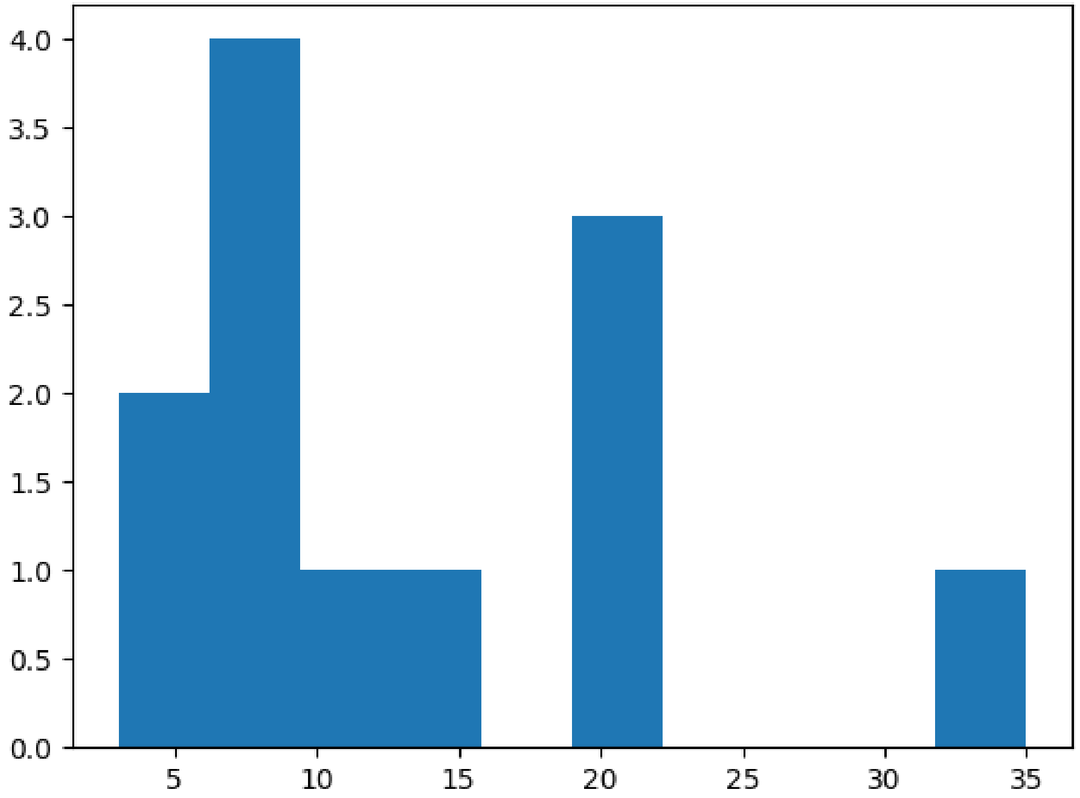

X 축 : 계급

히스토그램(Histogram)

```
plt.hist()
```

연속형 자료의 도수분포표를 기반으로 각 계급을 범주처럼 사용

범주형 자료의 **막대그래프**와 같은 방식으로 그림

히스토그램의 특징

- 자료의 분포를 알 수 있음
- 계급구간과 막대의 높이로 그림
- 모든 계급구간의 폭이 같으면

  도수, 상대도수를 막대 높이로 사용

도수다각형

Y 축 : 빈도

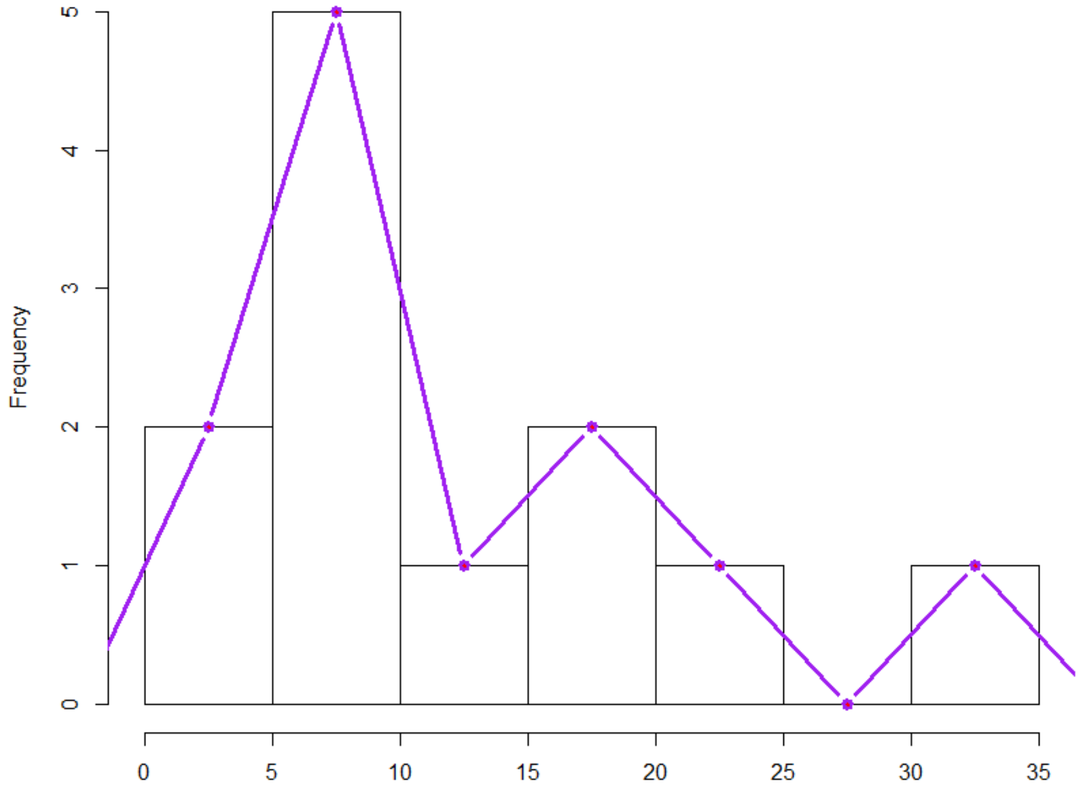

X 축 : 구간

도수다각형의 특징

- 각 계급구간의 중앙에 점을 찍어 직선으로 연결함
- 관측값의 집중된 위치, 정도, 치우친 정도, 꼬리의 두터움 등 분포의 상태를 쉽게 파악
- 관측값의 변화에 따라 도수 또는 상대도수의 변화를 잘 나타냄

도수다각형과 히스토그램

히스토그램	도수다각형
옆으로 나열하여 자료 비교	꺾은선으로 표시하여 자료 비교

여러 자료를 비교하기 위해서는

히스토그램보다 도수다각형이 알맞음

줄기-잎 그림

Y 축 : 잎

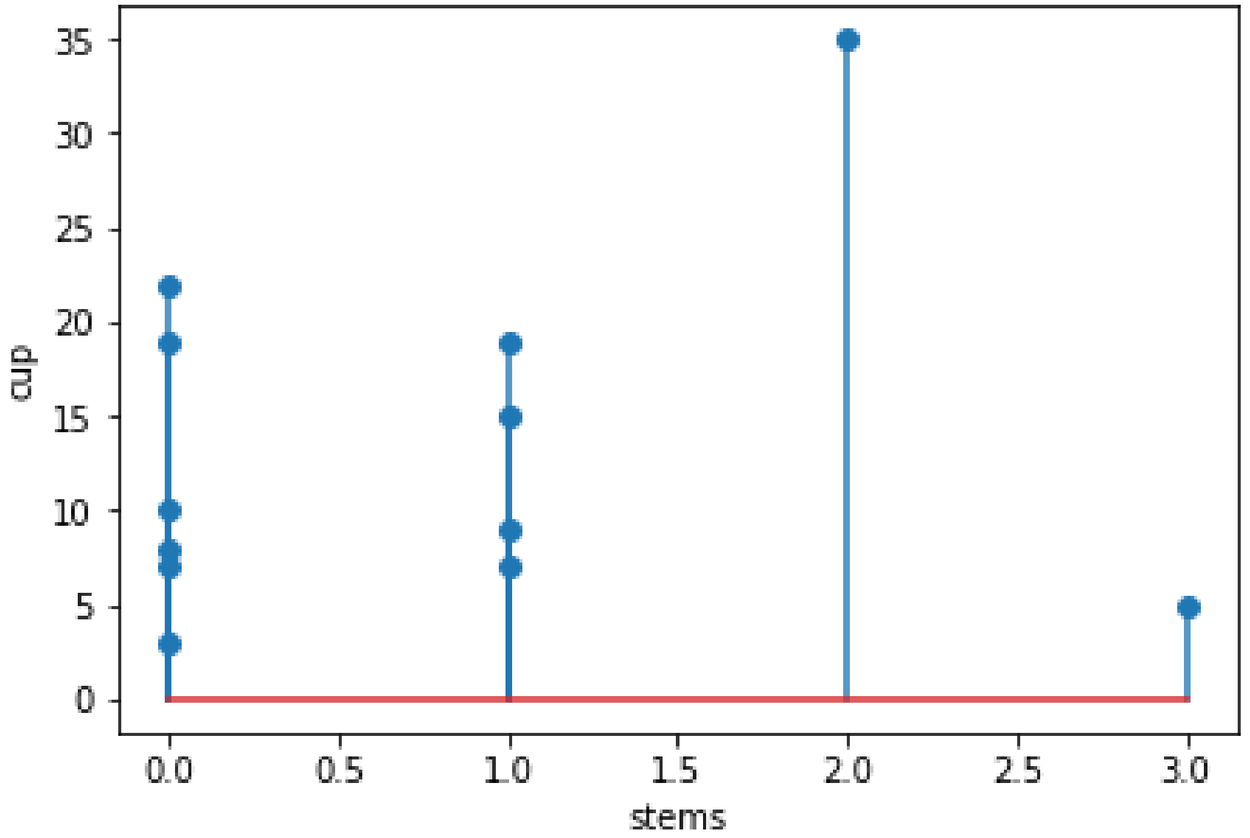

X 축 : 줄기

줄기-잎 그림 자료 정리 방법

예) 관측값의 자릿수가 최대 2자리 일때

관측값 35 → 앞 단위 : 3 + 뒷 단위 : 5

1. 관측값을 보고 앞 단위와 뒷 단위를 정함
2. 앞 단위를 줄기로 하여 세로로 배열하고 수직선을 그림
3. 뒷 단위를 잎으로 하여 관측값을 앞 단위 오른쪽에 오름차순 기입

줄기-잎 그림 함수

plt.stem(줄기, 관측 값)

자료의 분포를 시각적으로 쉽게 파악

각 관측값도 유지 가능

함수 사용 시에 줄기 값을 따로 지정해줘야 함

: 줄기를 데이터마다 다르게 설정할 수 있기 때문

줄기-잎 그림 장단점

장점

- 관측값을 보여주므로 최댓값, 최솟값 등의 위치 파악 쉬움
- 순서대로 배열된 관측값의 장점과 히스토그램의 장점을 모두 가지고 있음
- 그리기 쉬움

단점

- 관측값의 개수가 많은 경우 제한된 공간에 그리기 불가능
- 관측값이 지나치게 흩어져 있으면 부적절

[실습]

연속형 자료 요약 : 도수분포표, 줄기-잎 그림, 히스토그램